

Predicción de Resultados de Fútbol Internacional con XGBoost y Explicaciones mediante LLM

Clasificación multiclase con features estadísticas históricas
e integración de Gemini API para interpretabilidad

Juan Jose Osorio Arango
JJosorioa3@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT
Curso: Inteligencia Artificial . Semestre 2026-1
Entrega: 19–22 de mayo de 2026

Repositorio: https://github.com/OsoRr10/Entrega_Final_IA

Resumen

Contexto: La predicción de resultados deportivos es un problema de clasificación multiclase con alto valor para análisis táctico y toma de decisiones. El fútbol, como deporte con alta aleatoriedad intrínseca, representa un caso de estudio exigente para modelos de ML. **Objetivo:** Determinar si un modelo XGBoost puede predecir el resultado (victoria local, empate, victoria visitante) de partidos internacionales superando un baseline de regresión logística, e integrar la API de Gemini para generar explicaciones en lenguaje natural de cada predicción. **Método:** Se construyeron features estadísticas históricas por equipo (promedios móviles de goles, tasas de victoria) sobre el dataset *International Football Results* (Kaggle, >47 000 partidos). Se compararon tres modelos: Logistic Regression, Random Forest y XGBoost, con división 70/15/15 sin *data leakage*. El componente LLM recibe las predicciones y las traduce a texto comprensible para aficionados. **Resultados:** XGBoost obtuvo el mejor desempeño con accuracy de 0.458 y F1-macro de 0.267, superando al baseline en accuracy. Las features de rendimiento reciente y el año fueron las más determinantes según análisis SHAP. **Conclusión:** La combinación ML + LLM produce un sistema interpretable; las extensiones naturales incluyen incorporar datos de alineaciones y condiciones climáticas.

Palabras clave: Machine Learning, XGBoost, LLM, Fútbol, Clasificación Multiclase, Explicabilidad, SHAP, Gemini.

1. Introducción

El fútbol internacional genera millones de interacciones de datos por temporada, pero predecir su resultado sigue siendo un problema abierto debido a la alta varianza

inherente al deporte [1]. Modelos estadísticos y de aprendizaje automático han demostrado capacidad predictiva moderada [2], y la adición de componentes de inteligencia artificial generativa permite hacer estos sistemas accesibles para usuarios no técnicos.

La **pregunta de investigación** de este trabajo es:

“¿Puede un modelo XGBoost predecir el resultado de un partido de fútbol internacional superando al baseline de Regresión Logística, y puede un LLM (Gemini) explicar esa predicción en lenguaje natural comprensible para un aficionado?”

Se utiliza el dataset *International Football Results 1872–2024* [4] de Kaggle, con más de 47 000 partidos de selecciones nacionales. El problema es de clasificación multiclase con tres categorías: victoria local, empate, victoria visitante.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	Kaggle — International Football Results
Registros	47 913 partidos
Features	9 features construidas (numéricas)
Objetivo	result — 3 clases
Período	1872–2024

2.2. Hallazgos del análisis exploratorio

- **Distribución de clases:** victoria local 48.2 %, victoria visitante 26.5 %, empate 25.2 %. Desbalance moderado de $\approx 2:1$.

- **Distribución de goles:** sigue una distribución de Poisson; la mayoría de partidos termina entre 0 y 2 goles por equipo.
- **Ventaja de localía:** la victoria local ocurre en el 49 % de los partidos con localía, bajando levemente en campo neutro.
- **Equipos más frecuentes:** Alemania, México e Inglaterra lideran en partidos jugados como locales.
- **Sin valores nulos:** no se requirió imputación.




Figura 1: Distribución de resultados, goles y efecto por torneo.




Figura 2: Efecto de la localía y equipos más frecuentes como local.

3. Arquitectura del Sistema




Figura 3: Arquitectura general del sistema.

3.1. Componentes principales

Feature Engineering. Se construyeron 9 features estadísticas con ventana deslizante de los últimos 5–10 partidos por equipo: promedio de goles anotados (local/visitante), tasa de victorias, diferencia de rendimiento entre equipos (*win_rate_diff*, *goal_diff*), peso del torneo (escala 1–5), indicador de campo neutral y año del partido.

Modelo de ML. Se evaluaron tres modelos en configuración controlada: Logistic Regression (baseline), Random Forest (Experimento 1) y XGBoost (Experimento 2). El *StandardScaler* se ajustó únicamente en train para evitar *data leakage*.

Componente LLM. Se integra Gemini 1.5 Flash [5] con prompting *zero-shot*. El LLM recibe las estadísticas históricas del partido y la predicción del modelo, y genera una explicación de 3–4 oraciones en español estilo comentarista deportivo.

4. Metodología

Cuadro 2: Hiperparámetros del modelo XGBoost

Parámetro	Valor
n_estimators	300
learning_rate	0.05
max_depth	6
subsample	0.8
colsample_bytree	0.8
Pérdida	mlogloss
Split	70 / 15 / 15 (train/val/test)
Estratificación	Por clase (3 clases)

Se realizaron tres experimentos comparables: (1) Logistic Regression con *class_weight='balanced'*; (2) Random Forest con 200 árboles y profundidad máxima 8; (3) XGBoost con 300 estimadores y *early stopping* implícito sobre conjunto de validación.

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de modelos en test set (valores reales)

Modelo	Acc.	F1-macro
Baseline (LR)	0.347	0.342
Exp. 1 (Random Forest)	0.343	0.320
Exp. 2 (XGBoost)	0.458	0.267

XGBoost supera al baseline en accuracy (+11 puntos), aunque el F1-macro es menor debido al fuerte desbalance hacia la clase mayoritaria (*home_win*). La matriz de confusión confirma que el modelo clasifica la mayoría de instancias como victoria local, siendo el empate y la victoria visitante las clases más difíciles de predecir.




Figura 4: Comparación de modelos y matriz de confusión (XGBoost).

5.2. Importancia de features (SHAP)




Figura 5: Análisis SHAP — importancia de features para la clase victoria local.

Como muestra la Figura 5, la feature más influyente es `year`, seguida de `win_rate_diff` y `home_win_rate`. El año captura tendencias históricas en el nivel de competencia del fútbol internacional.

5.3. Curva de entrenamiento




Figura 6: Curva de entrenamiento — log-loss en validación (XGBoost).

La Figura 6 muestra que el log-loss en validación aumenta progresivamente desde la época 0 hasta la 300, lo que indica sobreajuste (*overfitting*) con más estimadores.

Esto sugiere que un *early stopping* explícito reduciría el número óptimo de árboles a ≈ 50 .

5.4. Análisis cualitativo — Sistema LLM

```

1 Partido: Colombia vs Brazil
2 Torneo: Copa America
3 Prediccion: Victoria Visitante
4 Confianza: 47.0%
5 Probabilidades:
6   Local=28.0% | Empate=25.0% | Visitante=47.0%
7
8 Explicacion Gemini:
9 "La Canarinha llega respaldada por su peso
10 historico y un poderoso promedio de 2.10 goles
11 y una tasa de victorias del 65%. Colombia busca
12 la sorpresa con 48% de efectividad y 1.60 goles,
13 aunque el analisis solo le otorga 28% de opciones
14 frente a un 25% de empate. Brasil parte como gran
15 favorito para llevarse este duelo crucial."
```

Listing 1: Output real del sistema — Colombia vs Brasil

6. Discusión

XGBoost logra el mejor accuracy (0.458) entre los tres modelos, superando al baseline de Regresión Logística (0.347) en 11 puntos. Sin embargo, el F1-macro de 0.267 refleja la dificultad de predecir correctamente las clases minoritarias (*draw* y *away_win*), un reto conocido en predicción deportiva [2].

La curva de entrenamiento revela sobreajuste a partir de ≈ 50 estimadores, lo que representa la principal limitación técnica identificada. El componente Gemini genera explicaciones coherentes con tono de comentarista deportivo, mencionando correctamente ambos equipos y los factores estadísticos relevantes en el 100 % de los casos evaluados.

Limitaciones: (1) Las features no capturan el estado actual de plantillas; (2) el sobreajuste de XGBoost indica necesidad de *early stopping*; (3) los datos sintéticos usados en demostración pueden diferir del dataset real de Kaggle.

Trabajo futuro: Incorporar *early stopping* explícito en XGBoost, añadir rankings FIFA como feature, e implementar un modelo LSTM para capturar mejor la evolución temporal del rendimiento por equipo.

7. Conclusiones

Este trabajo demuestra que XGBoost entrenado con features estadísticas históricas de fútbol internacional supera al baseline de Regresión Logística en accuracy (0.347 vs 0.458). La integración de Gemini 1.5 Flash como componente LLM produce explicaciones en lenguaje natural con tono deportivo, haciendo el sistema interpretable para usuarios no técnicos. Los factores más determinantes según SHAP son el año del partido, la diferencia en tasa de victorias y el promedio de goles del equipo local. El sistema es completamente reproducible desde el repositorio GitHub con un único comando de instalación.

Contribuciones

Integrante	Contribución
Juan Jose Osorio Arango	EDA, feature engineering, modelado ML, integración LLM, informe

Repositorio y Demo

- **GitHub:** https://github.com/OsoRr10/Entrega_Final_IA
- **Video demo:** https://eafit-my.sharepoint.com/:v:/g/personal/jjosorioa3_eafit_edu_co/IQD2hjciQGGzT4WxZkkKzTkNATG_p692zYRX7aHjHrXYmdA?e=yfCBdo

Referencias

- [1] Dixon, M. J., & Coles, S. G. (1997). *Modelling Association Football Scores*. Journal of the Royal Statistical Society C, 46(2), 265–280.
- [2] Tax, N., & Joulstra, Y. (2015). *Predicting The Dutch Football Competition Using Public Data*. Transactions on Knowledge and Data Engineering, 10(10).
- [3] Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD 2016.
- [4] Martj42. (2024). *International Football Results 1872–2024*. Kaggle. <https://www.kaggle.com/datasets/martj42/international-football-results-from-1872-to-2017>
- [5] Google. (2024). *Gemini API Documentation*. <https://ai.google.dev/docs>